

Token Düzeyi Olasılık Yörüngelerinden Yola Çıkararak Öznitelik ile Büyük Dil Modeli Cevap Doğruluğunun Tahmini

Umut Ünlü

Bilgisayar Mühendisliği Bölümü

Yıldız Teknik Üniversitesi

İstanbul, Türkiye

umut.unlu@std.yildiz.edu.tr

Özet—Bu çalışmada, büyük dil modellerinden birisi olan Qwen3.5-4B parametrelili modelin gsm8k_tr matematiksel sorularını cevaplarken token düzeyinde yörüngeleri (trajectory) izlenmektedir. Soru kütüphanesinden dil modelinin çözmediği sorular bazen çözdüğü bazense çözemediği sorular belirlenmektedir. Bunlardan 500 adet belirlenip 250 tanesi test için 250 tanesi rastgele bir şekilde kategorize edilmektedir. Her soru 10 kez çözülmektedir ve toplamda 5000 cevap oluşturulmaktadır. Bu sorularda çözüp çözemediği yörüngelerden belli matematiksel işlemlere göre öznitelikler çıkarılmaktadır. Burada çıkarılan öznitelikler 4 ana parametre kullanılarak oluşturulmuştur bunlar; ortalama top 10 toplamı, ortalama top 1 değeri, ortalama top 1 - top 2 değeri ve ortalama entropi değeridir. Bu özellikler kullanılarak oluşturulan 99 öznitelikler belirlendi. Bu özniteliklerin Ardından ablasyon işlemi ile 99 öznitelik 10'a düşürüldü ve XGBoost modeli bunlar ile eğitildi. Eğitilen model test kümesinde başarıları %84.8 doğruluk ve 0.877 ROC-AUC değeri elde edildi.

Index Terms—büyük dil modelleri, yörünge, entropi, doğruluk tahmini, XGBoost, gsm8k_tr

I. GİRİŞ

Büyük dil modelleri akıl yürütme ile verilen görevlerde başarı göstermektedir. Ancak zor ve karmaşık problemlerde bu akıl yürütme doğru sonuçlar kısmen üretmektedir. Bundan dolayı modelin ürettiği çıktıları kontrol etmek çözülmesi gereken problemlerden biridir.

Bu çalışmada bu problemi çözebilmek için literatürde de bulunan token düzeyinde akıl yürütmenin belirsizlikleri üzerinden bir saptama yapılacaktır. Bu saptama ile cevabın doğru olup olmadığı öngörülebilecektir.

Çalışmanın katkıları şunlardır:

- Türkçe matematik akıl yürütme verisi (gsm8k_tr) üzerinde, token düzeyi olasılık trajektorilerinden doğruluk tahmini yapan bir yöntem önerilmektedir.
- Top10 olasılık toplamı ve entropi trajektorilerinden, türev ve A^* esinli kümülatif sapma öznitelikleri çıkarılmaktadır.
- Ablasyon çalışması ile doğruluk sinyalinin az sayıda öznitelikte yoğunlaştığı gösterilmektedir.

II. İLGİLİ ÇALIŞMALAR

Dil modellerinde belirsizlik ölçümü, çıktı düzeyi kalibrasyonu ve token düzeyi entropi analizi olmak üzere çeşitli yönlerden incelenmiştir. Zhao [1], entropi trajektorisinin *şeklinin*

(magnitüdünden ziyade) akıl yürütme güvenilirliğini öngördüğünü göstermiştir. Bu çalışma, entropi monotonluğunun doğruluğun anlamlı bir yordayıcısı olduğunu ortaya koymuştur.

Bizim çalışmamız bu bulgudan farklı olarak, tekil bir metrik yerine çok sayıda token düzeyi öznitelikli bir makine öğrenmesi modeliyle birleştirmekte ve Türkçe veri kümesi üzerinde değerlendirmektedir.

III. YÖNTEM

A. Veri Kümesi ve Belirsiz Soru Seçimi

Çalışmada ytu-ce-cosmos/gsm8k_tr veri kümesi kullanılmıştır. Bu veri kümesi gsm8k'dan Türkçe diline çevrildiği için format dönüşümlerinde (nokta virgül gibi) hatalar olduğu fark edildi. Ayrıca bazı soruların cevaplarının belirsiz olmasından dolayı bu veri kümesinden belirsiz sorular seçilmeden önce ön işleme tabii tutulmuştur.

Modelin aynı soruya bazen doğru bazen yanlış cevap verdiği *belirsiz sorular* hedeflenmiştir. Bu soruların seçilmesinin nedeni aynı soruya doğru ve yanlış cevaplar verirken tokenların yörüngesinde ne gibi farklılıklar olduğunun olanak tanıdığı içindir. İlk olarak her soruya 3 cevap üretilirdi ve bu cevaplar arasından en az bir tanesi doğru ve en az bir tanesi yanlış olanlar aday olarak belirlendi. Daha sonrasında bu aday sorulara 10 kez tekrar sorular çözdürüldü. Çıkan bu 500 soru ve 5000 cevap, her soru kendi cevaplarında yer alacak şekilde 250 soru 2500 cevap eğitim için 250 soru 2500 cevap test için rastgele olacak şekilde ayrıldı.

B. Cevap Üretimi ve Metrik Çıkarımı

Qwen3.5-4B modeli ile her soruya 10 cevap üretilmiştir (temperature = 1.0, top_p = 0.95, top_k = 20). Her token için, modelin ham logit dağılımından dört metrik hesaplanmıştır:

- **top10_sums**: En yüksek olasılıklı 10 token'ın olasılık toplamı.
- **top1_probs**: En yüksek olasılıklı token'ın olasılığı.
- **top1_top2_fark**: Birinci ve ikinci olasılık arasındaki fark.
- **entropy**: Olasılık dağılımının Shannon entropisi.

Entropi şu şekilde tanımlanır:

$$H = - \sum_{i=1}^V p_i \log(p_i) \quad (1)$$

Burada V kelime hazinesi boyutu, p_i ise i . token'ın olasılığıdır.

Token düzeyi gürültüyü azaltmak için her metriğe pencere boyutu 5 olan hareketli ortalama uygulanmıştır.

C. Öznitelik Çıkarımı (Feature Extraction)

Değişken uzunluktaki token serilerinden yola çıkarak sabit boyutlu vektörlere dönüştürüldü. Bu dönüşüm yapılırken istatistiksel özetleme kullanıldı. Her metrik için aşağıdaki öznitelik grupları çıkarılmıştır:

- İstatistiksel özetler (ortalama, standart sapma, min, maks)
- Bölümsel ortalamalar (ilk/son %33)
- Trend (son bölüm – ilk bölüm)
- Dalgalanma (komşu farkların mutlak ortalaması)
- A^* esinli sapma metrikleri (maksimum sapma, sapma pozisyonu, kümülatif sapma)
- Birinci ve ikinci türev istatistikleri ve dönüm noktaları
- Eşik tabanlı oranlar ve pozisyonel öznitelikler

Ek olarak, [1] buna benzer ilgili çalışmadan uyarlanan entropi monotonluğu, ihlal sayısı ve son adım entropisi öznitelikleri eklenmiştir. Toplam 99 öznitelik elde edilmiştir.

D. Sınıflandırma

Tablo verisindeki yüksek performansı, öznitelik önem analizi sağlaması ve sınıf dengesizliğini yönetebilmesi nedeniyle XGBoost sınıflandırıcısı tercih edildi. Sınıf dengesizliği `scale_pos_weight` parametresi ile düzeltilmiş, aşırı öğrenmeyi önlemek için sığ ağaçlar (`max_depth = 4`), düşük öğrenme oranı (0.05) ve erken durdurma kullanıldı. Nitekim çalışma sırasında aşırı öğrenmeyi önlemek için 81 ağaçta eğitim durmaktadır.

IV. DENEYSEL SONUÇLAR

A. Genel Performans

Test kümesi üzerinde elde edilen sonuçlar Tablo I'da sunulmaktadır.

Tablo I
TEST KÜMESİ PERFORMANS METRİKLERİ (10 ÖZNİTELİK)

Metrik	Değer
Doğruluk (Accuracy)	0.848
F1 Skoru	0.782
ROC-AUC	0.877

Model, cevabın içeriğine hiç bakmadan yalnızca güven sinyalleriyle %84.8 doğruluk elde etmiştir. ROC-AUC değeri 0.877, modelin doğru ve yanlış cevapları ayırt etme gücünün yüksek olduğunu göstermektedir.

B. Karmaşıklık Matrisi

Tablo II karmaşıklık matrisini göstermektedir. Model yanlış cevapları %93 duyarlılıkla yakalamakta, doğru cevaplarda ise daha temkinli davranmaktadır.

Tablo II
KARMAŞIKLIK MATRİSİ

	Tahmin: Yanlış	Tahmin: Doğru
Gerçek: Yanlış	1438	101
Gerçek: Doğru	279	682

C. Ablasyon Çalışması

Öznitelik önem skorlarına dayanan ablasyon çalışmasında, farklı önem eşiklerinde model yeniden eğitilmiştir (Tablo III). 99 öznitelikten 10'una inildiğinde performans korunmuş; 10'un altına inildiğinde ise düşüş gözlenmiştir. Bu bulgu, token düzeyi istatistiklerinin yüksek oranda fazlalık (redundant) içerdiğini göstermektedir. Aşağıda AUC değerlerine en yüksek ve en düşük 20 öznitelik görülmektedir.

Tablo III
ÖZNİTELİK SAYISINA GÖRE ABLASYON SONUÇLARI

Öznitelik Sayısı	Doğruluk	ROC-AUC
99	0.853	0.876
66	0.852	0.877
25	0.847	0.877
10	0.848	0.877
7	0.855	0.873
6	0.854	0.872

En bilgilendirici öznitelikler; cevap uzunluğu, entropi dönüm noktalarının pozisyonu, kümülatif sapma ve son adım entropisi olarak belirlenmiştir.

V. TARTIŞMA VE SINIRLAMALAR

Sonuçlar, token düzeyi güven dinamiklerinin doğruluk tahmininde güçlü bir sinyal taşıdığını doğrulamaktadır. Ancak çalışmanın bazı sınırlamaları bulunmaktadır: değerlendirme yalnızca matematik akıl yürütme (`gsm8k_tr`) ve tek bir model (Qwen3.5-4B) üzerinde yapılmıştır. Ayrıca model, yalnızca belirsiz sorular üzerinde test edilmiştir; çok kolay veya çok zor sorularda davranış farklılık gösterebilir.

VI. SONUÇ

Bu çalışmada, bir büyük dil modelinin Türkçe matematik sorularına verdiği cevapların doğruluğu, yalnızca token düzeyi olasılık sinyalleri kullanılarak elde edilen öznitelikler ile eğitilen XGBoost modeli ile %84.8 doğruluk ve 0.877 ROC-AUC ile tahmin edilmiştir. Ablasyon çalışması, bu performansın yalnızca 10 öznitelik ile elde edilebildiğini ortaya koymuştur. Gelecek çalışmalarda yöntemin farklı görevler ve modeller üzerinde genellenebilirliği incelenebilir. Ek olarak modelin yanlışları yakalama konusundaki performansı %94 seviyesindeken doğruları yakalama konusunda ise %70 gibi bir değer sahiptir. Bunun nedeni sınıf dengesizliğinden kaynaklanmış olabilir. İleriki çalışmalarda sınıf dengesizliğinin doğru cevapların fazla olduğu cevap havuzu kullanılarak eğitilen ve test edilen model ile sonuçları karşılaştırılabilir.

KAYNAKLAR

- [1] X. Zhao, “Entropy trajectory shape predicts LLM reasoning reliability: A diagnostic study of uncertainty dynamics in chain-of-thought,” *arXiv preprint arXiv:2603.18940*, 2026.